RAG 메뉴얼



Milvus 버전

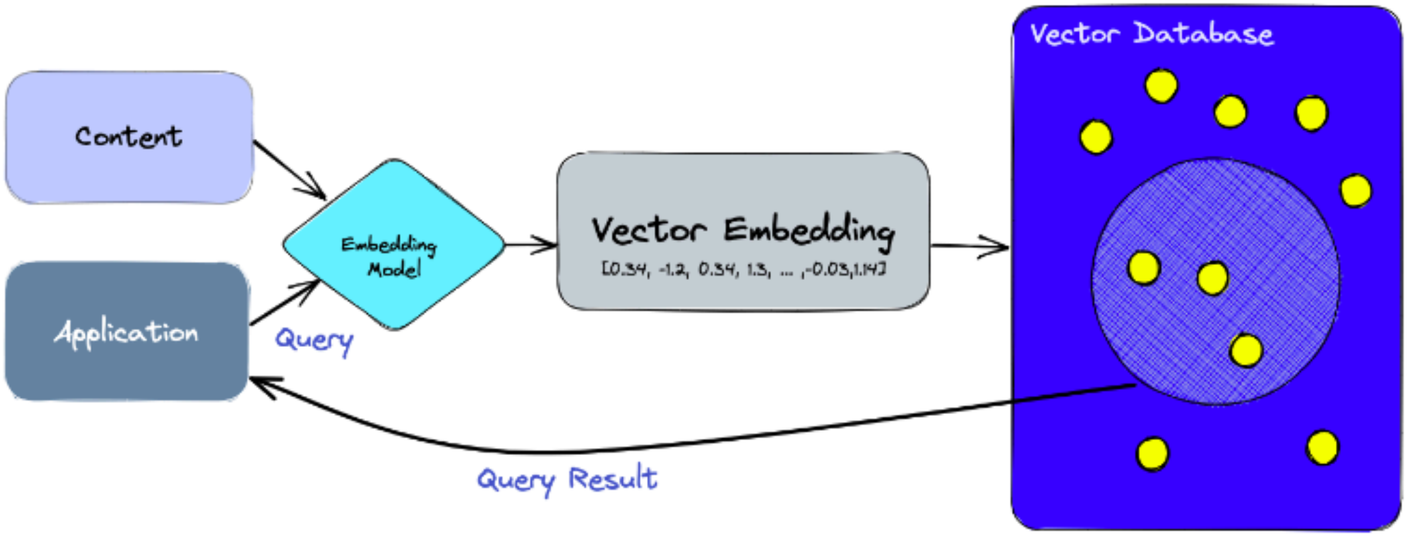
2026-03-30

관리자: 김건일 박사과정

목차

1. VectorDB 개념
2. VectorDB 비교
3. 임배딩 모델
4. Milvus 소개
5. RAG 구축
5.1 (GUI 사용) Milvus Attu 접속
5.2 (Python 사용) PyMilvus 접속

VectorDB 개념



1. **데이터 관리:** 삽입 삭제 업데이트와 벡터 인덱스를 사용하는 것보다 벡터 데이터를 쉽게 관리하고 유지할 수 있다.
2. **메타데이터 저장 및 필터링:** 벡터 항목 관련 메타데이터를 저장할 수 있다. 필터를 이용하여 DB쿼리 가능
3. **확장성:** 데이터 양이 많아질 수록 분산 및 병렬 처리됨 (샤딩, 수평 분할)
4. **실시간 업데이트:** 실시간 데이터 업데이트를 지원(동적으로 변경 가능)
5. **백업 및 수집:** 모든 데이터를 백업하는 일상적인 작업 처리(배치), Collections 형태로 백업 가능(NoSQL 특성)
6. **에코시스템 통합:** Spark, 태블로, 그라파나 같은 분석, 시각화 툴들과 생태계 연동 가능

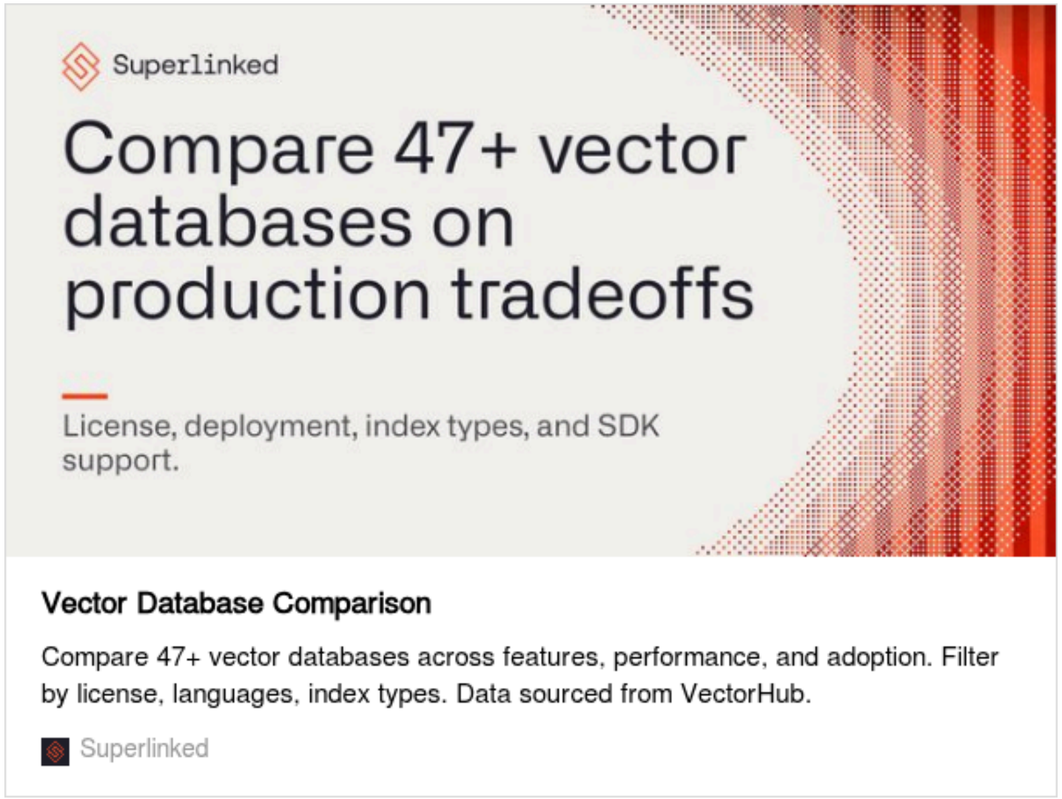
VectorDB 비교

milvus

Chroma

Pinecone

qdrant



Source: https://superlinked.com/vector-db-comparison

Azure Cosmos DB

Weaviate

Postgres + PG Vector

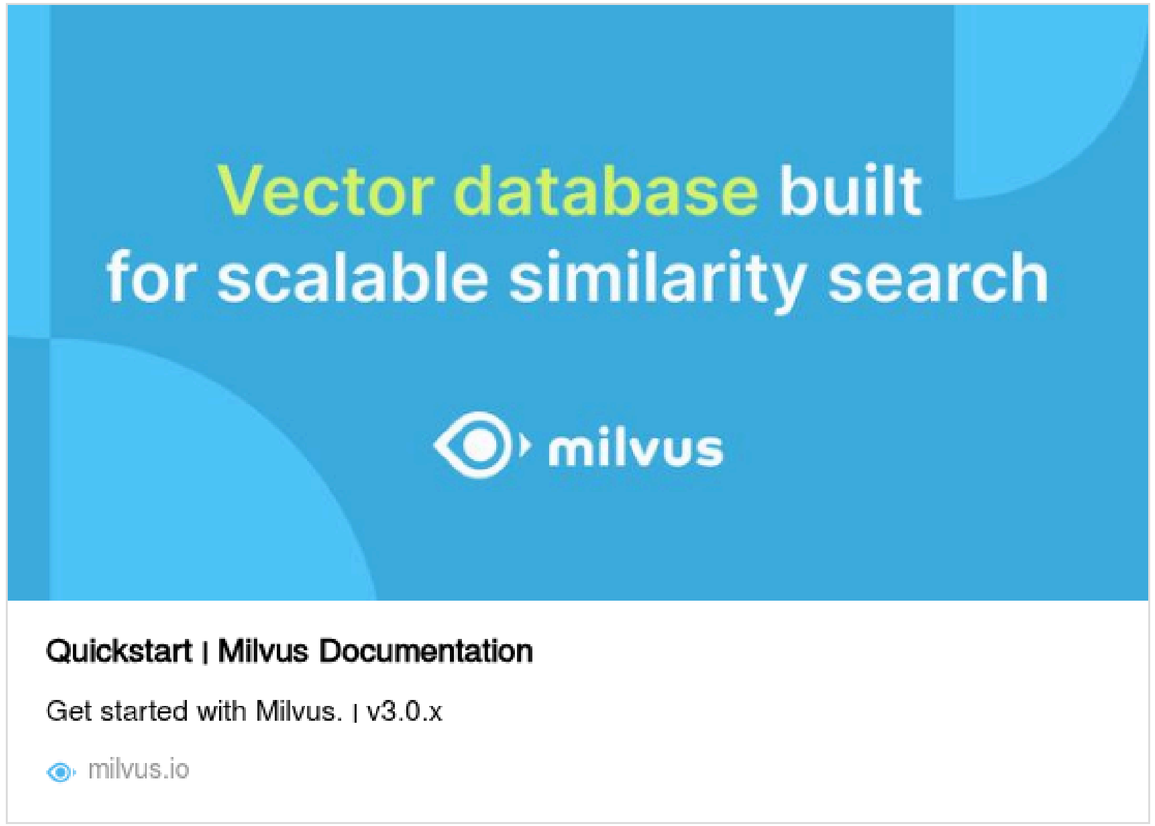
LanceDB

임배딩 모델

서버 경로: /mnt/nvme01/huggingface/models/ + (모델명)

언어 지원	모델명	차원(Dimension)	모델 사이즈	Max Seq Length (토큰)
영어만	Alibaba-NLP/gte-base-en-v1.5	768	137M	8192
	Alibaba-NLP/gte-large-en-v1.5	1024	434M	8192
	BAAI/bge-base-en-v1.5	768	109M	512
	BAAI/bge-large-en-v1.5	1024	335M	512
다국어 (영어 / 한국어 지원)	Alibaba-NLP/gte-multilingual-base	768	305M	8192
	BAAI/bge-m3	1024	-	8192
	BAAI/bge-multilingual-gemma2	4096	9.24B	8192

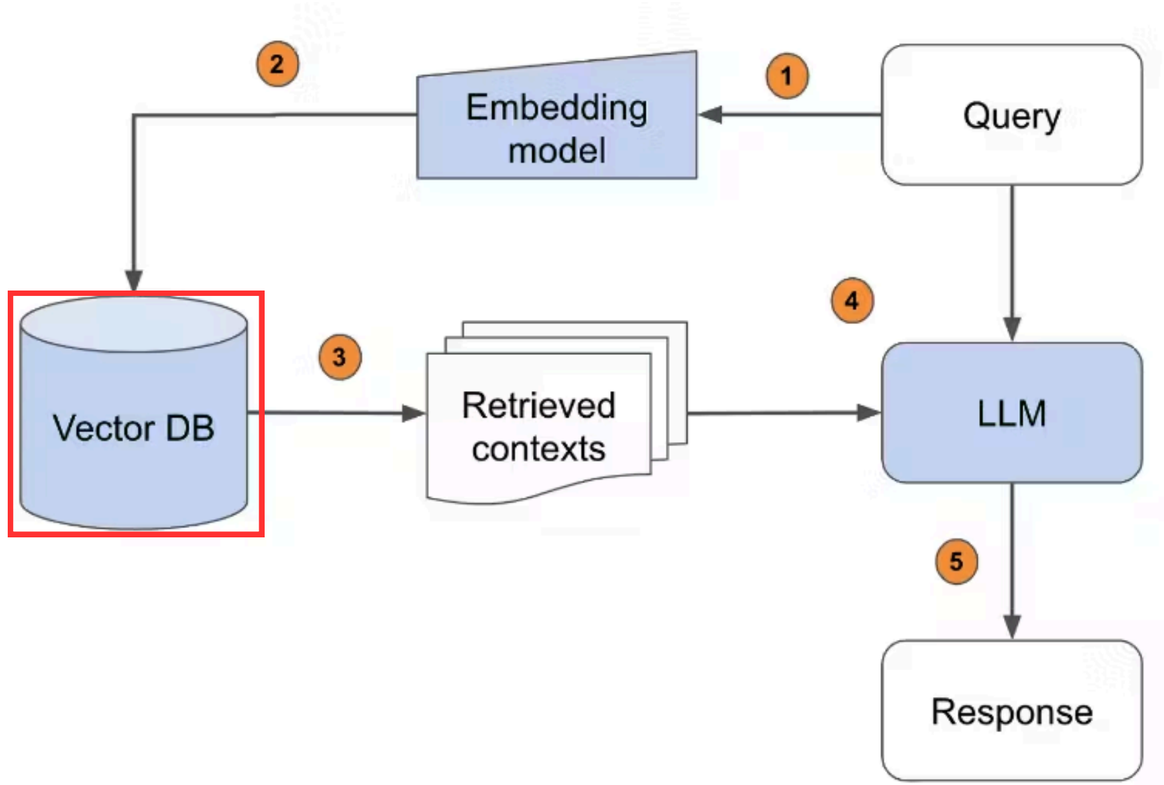
Milvus 소개



Source: https://milvus.io/docs/ko/quickstart.md

RAG 구축 - 인덱싱 방법

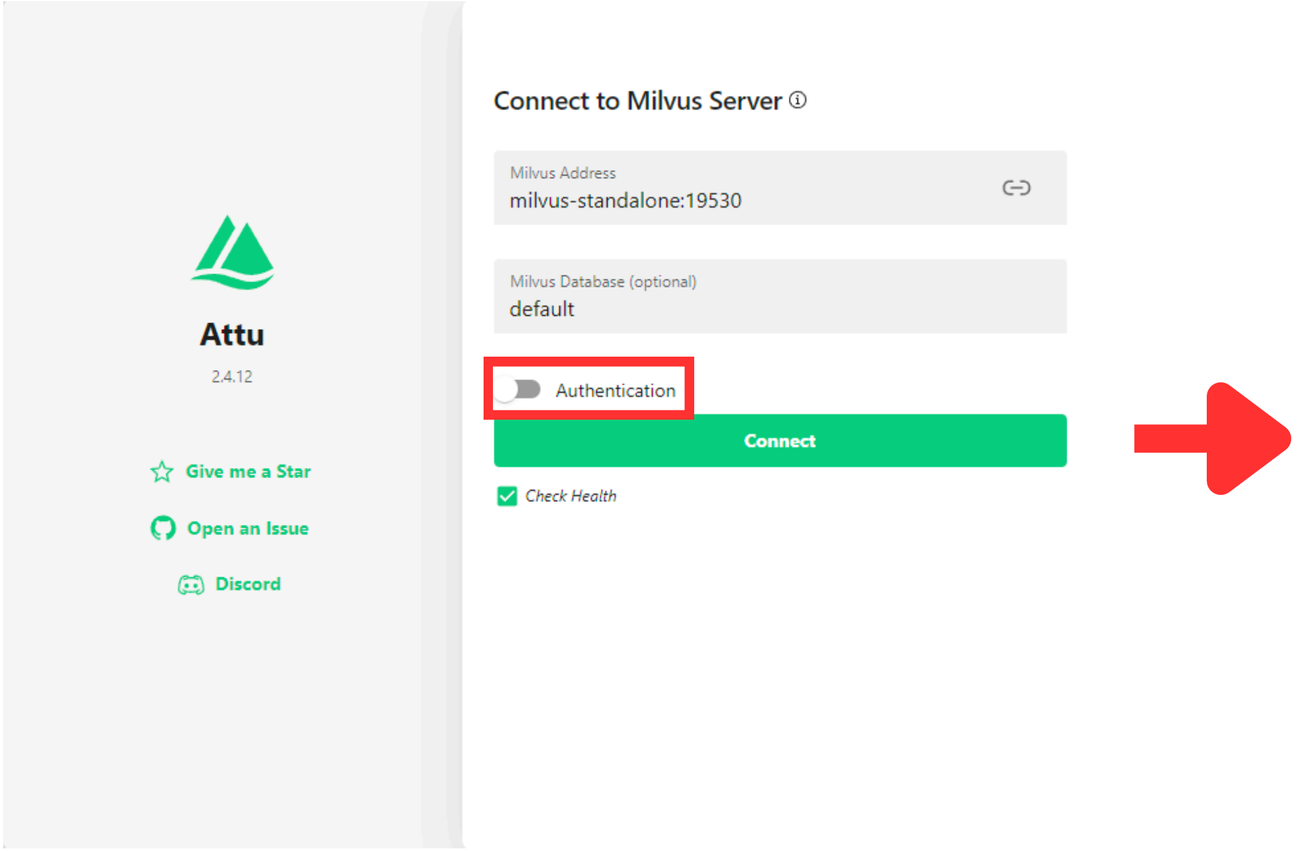
분류	구축 기반	인덱싱 종류	유사도 측정 항목
In-Memory	CPU + RAM 메모리	FLAT (IVF / IVF-SQ8 / PQ)	Euclidean Distance (**L2**) / Inner Product (**IP**)
		HNSW	
		SCANN	
On-Disk (현재 서버에 사용 중)	**SSD / NVMe 메모리**	**DiskANN**	Euclidean Distance (**L2**) / Inner Product (**IP**) / Cosine
GPU	그래픽 카드 메모리	GPU_CAGRA	Euclidean Distance (**L2**) / Inner Product (**IP**)
		GPU_IVF_PQ / GPU_IVF_Flat	
		GPU_BRUTE_FORCE	

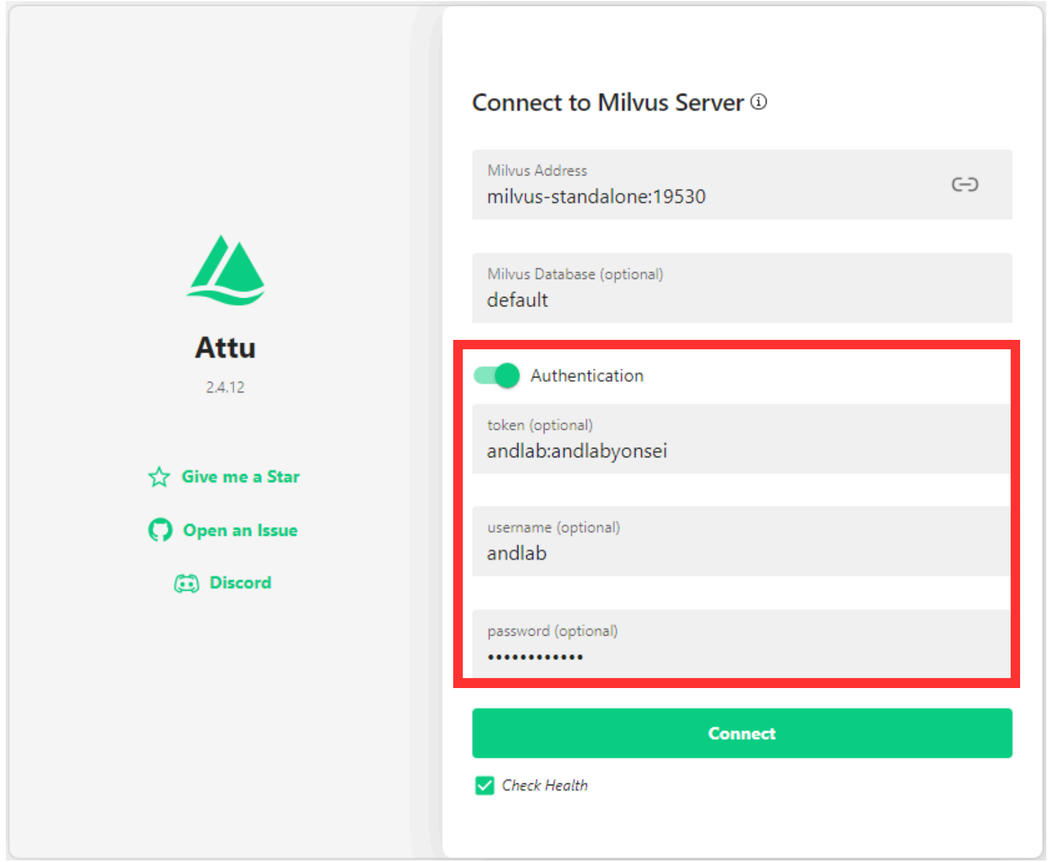


Source: https://milvus.io/docs/v2.4.x/index.md?tab=floating

Milvus Attu 접속

접속 사이트 주소(URL): http://165.132.193.69:8000





Login

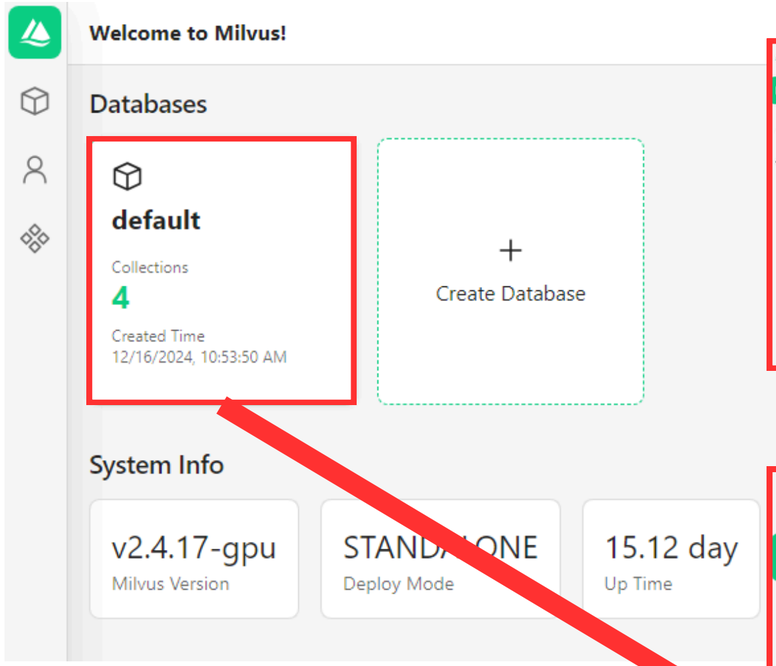
token(optional): andlab:andlabyonsei
username(optional): andlab
password(optional): andlabyonsei

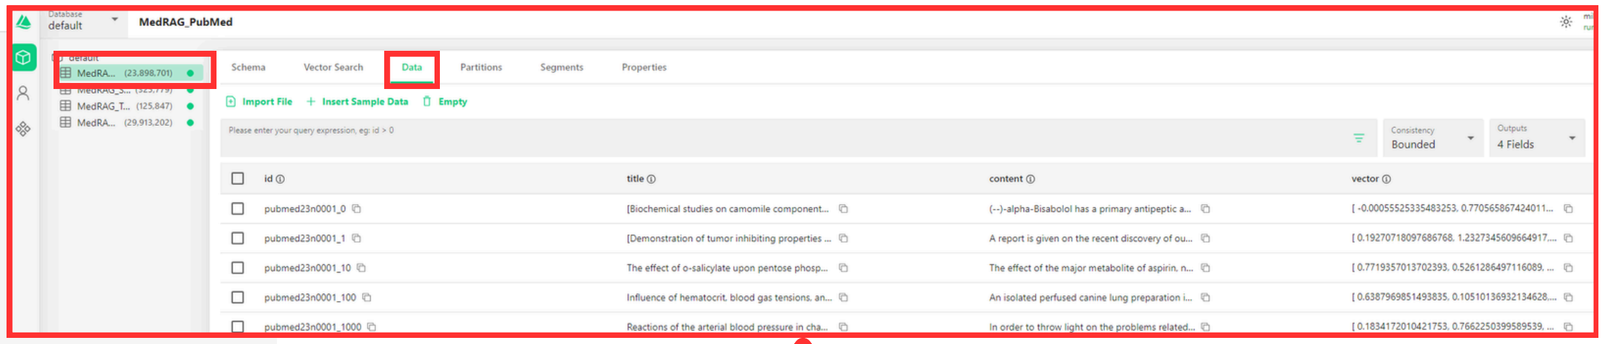
Milvus Attu 접속

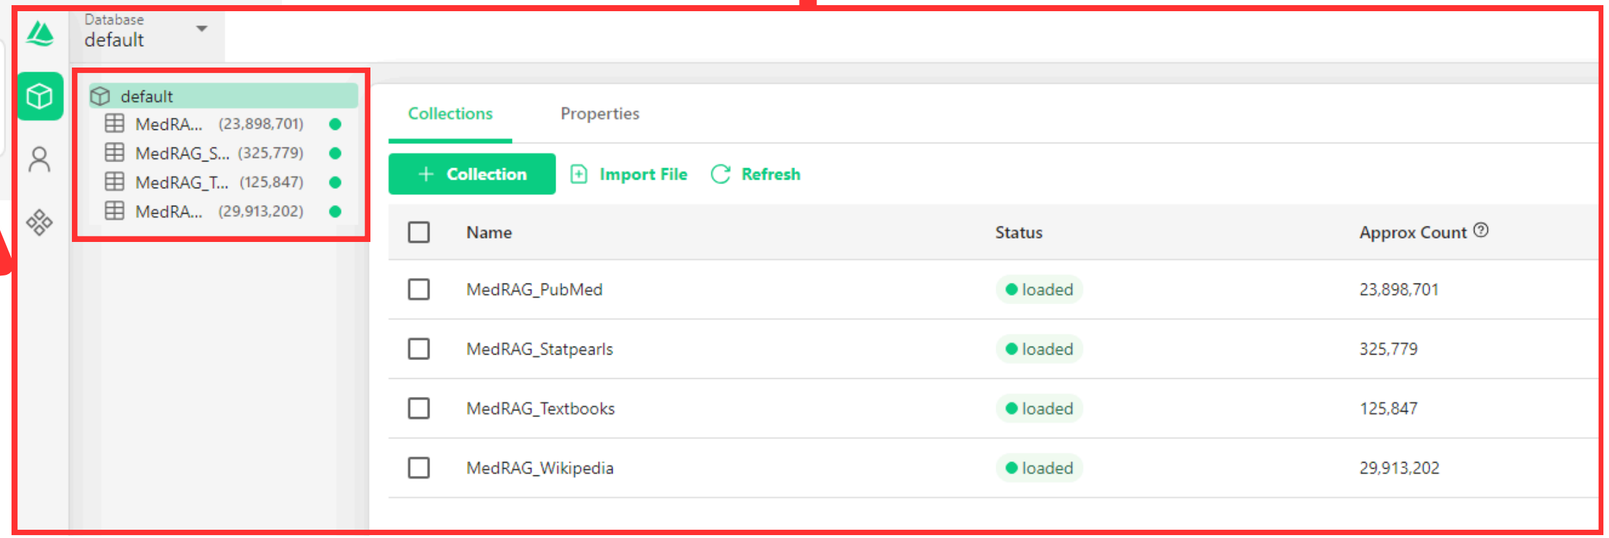
접속 사이트: http://165.132.193.69:8000

구축된 RAG 문서 리스트

MedRAG - PubMed ==> chunk된 약 23억 텍스트
MedRAG - StatPearls ==> chunk된 약 32만 텍스트
MedRAG - Textbooks ==> chunk된 약 12만 텍스트
MedRAG - Wikipedia ==> chunk된 약 29억 텍스트







PyMilvus 접속

RAG_search.py

Code > preprocessing > RAG_search.py > ...

Run Cell | Run Below | Debug Cell

```python
# %%
from pymilvus import connections, Collection
from sentence_transformers import SentenceTransformer

model_folder = '/mnt/nvme01/huggingface/models/'
embed_name = model_folder + "Alibaba-NLP/gte-large-en-v1.5"
encoder = SentenceTransformer(embed_name, trust_remote_code = True)
connections.connect(host = "localhost", port = "19530", token = "andlab:andlabyonsei")
collection_lists = ['MedRAG_PubMed', 'MedRAG_Wikipedia', 'MedRAG_Statpearls', 'MedRAG_Textbooks']
```

Run Cell | Run Above | Debug Cell

```python
# %%
rag_contents = []
for names in collection_lists:
    collection = Collection(name = names)

    res = collection.search(
        data = encoder.encode(["tell me about chicken-pox related information"]),
        anns_field = "vector",
        param = {"metric_type": "IP",
                 "search_list" : 8},
        limit = 1,
        output_fields = ["id", "content"],
    )
    rag_contents.append(res[0][0].content)

print(rag_contents)
```

임베딩 코드

쿼리 및 검색 코드

```
rag_contents
[3] ✓ 0.0s
... ['Varicella (chicken pox) is a highly contagious disease which is caused by Varicella Zoster Virus (
 'Chickenpox occurs in all parts of the world. In 2013 there were 140 million cases of chickenpox ar
 'Chickenpox or varicella is a contagious disease caused by the varicella-zoster virus (VZV). The vi
 'EPIDEMIOLOGY AND CLINICAL MANIFESTATIONS Chickenpox Humans are the only known reservoir for VZV. C
```

사용자 계정별>

먼저 “pip install pymilvus==2.6.11 sentence-transformers” 설치해야함

RAG 검색 방법:

1. 임베딩 모델 설정
2. 인코딩할 쿼리 입력


Thank
you!